

Normalização, Padronização e Escalonamento

Como equilibrar grandezas distintas para garantir modelos de Machine Learning estáveis, justos e convergentes.

INTEGRANTES DA EQUIPE

João Góes • João Suzuki • Cláudio Jayme • Davi Miguel • João Gabriel Barros • Avya Alex • Gabriel Cunha • Pedro Prevides • Gustavo Lima

O Problema: Escalas e Grandezas



Analogia: Altura vs. Salário

Cegueira Semântica: Algoritmos enxergam apenas 1.8 contra 5.000.

Distorção de Distância: Variação de R\$ 50 supera qualquer altura.

Efeito Prático: O salário domina 100% dos cálculos.



Caso Real: Sensores Industriais

Grandezas Discrepantes: Vibração (~2 mm/s) vs Energia (~100 kWh).

Sinal Crítico: Salto de vibração de 2 para 8 funde o motor.

Falha do Modelo: O modelo ignora vibração por ser numericamente pequena.

Conclusão Operacional: Sem reescalonamento, magnitude matemática sufoca a relevância estatística.



Por que essa Técnica foi Criada?

Os três grandes benefícios práticos que fundamentam a modelagem moderna



1. Distância Justa

Equilíbrio Espacial: Algoritmos de proximidade (KNN, K-Means) tratam todas as variáveis com paridade geométrica real.



2. Treino Rápido

Convergência Estável: Evita oscilações extremas do gradiente descendente em Redes Neurais e otimizadores convexos.



3. Interpretação Clara

Análise Confiável: Permite comparação visual direta de coeficientes e identificação dos reais gatilhos de falha.



Breve Histórico das Técnicas

SÉC. XIX (1801)

Carl F. Gauss

Órbita de Ceres: Método dos mínimos quadrados e curva normal de dispersão.



1890 - 1900

Karl Pearson

Formalização do Z-Score: Comparação de fenômenos biológicos em unidades de desvio padrão.



1970 - HOJE

Machine Learning

Scikit-Learn e MLOps: Padronização como etapa mandatória em pipelines industriais modernos.



Evolução Contínua: Da astronomia à IA contemporânea, o controle de dispersão viabilizou a computação preditiva.

Normalização Min-Max

Mapeamento estrito de variáveis contínuas em intervalos delimitados [0, 1]

FORMULAÇÃO MATEMÁTICA

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Preserva exatamente a distância proporcional original entre todos os pontos amostrados.

Onde Brilha (Casos Ideais)

Processamento de imagens (pixels [0, 255]), redes com ativação Sigmoid/Tanh e matrizes esparsas.

Vulnerabilidade a Outliers

Um único valor anômalo extremo comprime todos os dados saudáveis em uma faixa microscópica.

StandardScaler e RobustScaler

Centralizando distribuições e protegendo dados contra discrepâncias extremas

StandardScaler (Z-Score)

Média = 0

$$Z = \frac{X - \mu}{\sigma}$$

Variância Unitária: Converte para unidades de desvio padrão.

Sem Limites Rígidos: Outliers ficam visíveis acima de $\pm 3\sigma$.

Premissa: Perfeito para distribuições gaussianas.

RobustScaler (Quartis)

Mediana + IQR

$$X_{\text{rob}} = \frac{X - \text{Mediana}}{Q_3 - Q_1}$$

Imunidade Central: Mediana e IQR ignoram picos isolados.

Essencial na Indústria: Não distorce a faixa de máquinas sadias.

Recomendação: Melhor opção quando há presença de ruídos.

Padrão Ouro: Usar StandardScaler para modelos lineares/redes e RobustScaler em séries industriais ruidosas.

Comparação entre as Técnicas

Guia prático para a escolha correta do escalador no pipeline

Técnica	Escala Resultante	Sensibilidade Outliers	Principal Indicação
MinMaxScaler	[0, 1] rígido	Muito Alta (Crítica)	Imagens, pixels e limites físicos
StandardScaler	$\mu = 0, \sigma = 1$	Média / Alta	PCA, Regressão, Redes Neurais
RobustScaler	Centrado na mediana	Baixa (Robusto)	IoT ruidoso e sensores fabris

Sensíveis vs. Imunes à Escala

Nem todos os modelos necessitam de reescalonamento; saiba quando aplicar



Modelos Altamente Sensíveis

KNN & K-Means: Proximidade euclidiana quebra com escalas desiguais.

SVM: Maximização de margens é destruída por dispersões assimétricas.

PCA: O primeiro componente projeta unicamente a coluna de maior valor.

Redes Neurais: O gradiente descendente oscila severamente.



Modelos Imunes (Não Obrigatório)


Árvores de Decisão: Cortes univariados dependem apenas da ordenação.

Random Forest & XGBoost: Invariantes à monotonicidade das grandezas.

Naive Bayes Puro: Avalia densidades e probabilidades coluna a coluna.

Regras de Associação: Mineração lógica opera sobre conjuntos discretos.

Manutenção Preditiva na Indústria 4.0



-38%

Paradas não programadas

94%

Acurácia (era 71%)

Detecção Antecipada: A padronização dos sensores permitiu identificar a deterioração de rolamentos com **18 dias de antecedência**, impedindo a quebra de 120 turbinas monitoradas.

APRESENTADOR: GABRIEL CUNHA

Tendências Modernas em Escalonamento

Da estabilização de LLMs à execução ultraeficiente de modelos em borda



Batch & LayerNorm

Base dos Transformers: Estabiliza representações vetoriais de bilhões de parâmetros em modelos generativos.



Quantização (FP8 / INT8)

Edge Computing: Escalonamento dinâmico viabiliza IA avançada em smartphones e microcontroladores com economia de RAM.



Streaming Scalers

Algoritmo de Welford: Recalcula média e variância dinamicamente em fluxos contínuos de IoT sem reprocessar histórico.

O escalonamento deixou de ser estático e tornou-se parte intrínseca da inferência.

FRONTEIRA DA IA

Trabalho Prático: Dataset Criado

Construção do dataset de sensores industriais (dados_maquinas.csv • 60 leituras)

Estrutura das Variáveis

temperatura_c: Faixa típica 65–76 °C.

vibracao_mm_s: Faixa normal 2.0–3.25 mm/s.

consumo_kwh: Faixa regular 80–107 kWh.

horas_operacao: Turnos contínuos de 6 a 10 horas.

Metadados: Identificador, data e flag de falha (sim/não).

Requisitos & Desafios Inseridos

2 Nulos Propositais: Reg. 12 (temperatura) e Reg. 26 (consumo).

3 Anomalias Univariadas: Reg. 7 (115 °C), Reg. 18 (9.5 mm/s), Reg. 31 (180 kWh).

Anomalia Combinada (Reg. 44): Alta temperatura (95 °C) + alta vibração (8.0 mm/s) → falha confirmada.

Tratamento e Feature Engineering

Pipeline de preparação com Pandas e Scikit-Learn



1. Limpeza e Imputação

Inspeção Inicial: Avaliação de nulos com `.isna().sum()`.

Imputação Robusta: Preenchimento de faltantes pela mediana, blindando os dados contra desvios causados por outliers.



2. Criação de Atributos

energia_por_hora: Consumo elétrico dividido pelas horas de operação.


indice_estresse: Combinação ponderada de vibração, temperatura e energia.

Escalonamento Paralelo: Aplicação comparativa dos três escaladores.

Resultados: Boxplots Antes vs. Depois


Efeito do StandardScaler

Antes do Escalonamento



Consumo e Temperatura ocultam Vibração e Horas

Depois do StandardScaler




Escala unificada em $\mu=0$ • Outliers claramente isolados em $+6\sigma$

Conclusão: Todas as 4 grandezas agora possuem o mesmo peso e relevância analítica no modelo.

Paridade Estatística

Detecção de Falha: Temperatura x Vibração

Anomalia Crítica (Registro 44)



Anomalias Isoladas

Picos de vibração isolada (9.5 mm/s) ou calor puro (115 °C) geraram alertas, mas a máquina continuou operando.

Falha Combinada Confirmada

O Registro 44 (95 °C e 8.0 mm/s) disparou o pico do Índice de Estresse, sendo a única ocorrência de falha = 'sim'.

Conclusões e Considerações Finais

1. Etapa Mandatória

O escalonamento não é cosmético: é o fundamento para convergência rápida e equilíbrio em IA.

2. Escolha Consciente

StandardScaler para premissas estatísticas;
RobustScaler para ambientes ruidosos e IoT.

3. Código e Reprodutibilidade

Pipeline 100% implementado em Python e
Scikit-Learn com dataset de validação testado.

Obrigado pela Atenção!

Perguntas & Discussão

Image Sources



<https://cdn.britannica.com/27/190027-050-A9A35298/Carl-Friedrich-Gauss-engraving.jpg>

Source: www.britannica.com



<https://ifactoryapp.com/industries/power-plant/manage-post-2k26/uploads/vibration-sensor-predictive-analytics-turbines.png>

Source: ifactoryapp.com